# Erkennung fehlerhafter Bezahlvorgänge an Selbstbedienungskassen im Einzelhandel

### Projektauftrag

Dominik Lewin, Johannes Winkler, Mario Teßmann 21. April 2024

## 1 Auslöser

### 1.1 Problemstellung

Das auftraggebende Unternehmen hat im Jahr 2016 Selbstbedienungskassen (SB-Kassen) in ihrem stationären Lebensmitteleinzelhandel in Hagen eingeführt. Der Auftraggeberin ist aufgefallen, dass die Anzahl fehlerhafter Bezahlvorgänge seit der Inbetriebnahme der SB-Kassen angestiegen ist. Um einen fehlerhaften Bezahlvorgang handelt es sich, wenn nicht alle Artikel eines Einkaufs korrekt eingescannt werden und dementsprechend nicht bezahlt werden. Empirische Untersuchungen haben ergeben, dass ca. 5% aller Scanvorgänge fehlerhaft sind.

### 1.2 Hintergrundwissen

### 1.2.1 Funktionen einer SB-Kasse

SB-Kassen werden im Einzelhandel eingesetzt, um Kunden zu ermöglichen, ihre Einkäufe selbst zu scannen und anschließend an einem integrierten Bezahlterminal zu bezahlen.

Die Ziele der Einführung von SB-Kassen sind vielfältig: Zum einen möchte der Einzelhändler Personalkosten einsparen, da weniger Kassierer gebraucht werden. Des Weiteren sollen die SB-Kassen für eine Arbeitserleichterung bei den Angestellten sorgen. Letztlich verspricht man sich auch eine Steigerung der Kundenzufriedenheit, da durch die Einführung der neuen Kassen lange Schlangen vermieden werden können.

An den SB-Kassen der Auftraggeberin stehen dem Kunden folgende Anwendungsmöglichkeiten der Kasse zur Verfügung:

- Artikel scannen
- Artikel stornieren
- Hilfe anfordern (Probleme, Altersfreigabe)
- Bezahlung mit Karte oder Bargeld
- ggf. Auswahl der Anzahl eines Artikels
- Obst / Gemüse / Backware auswählen und ggf. die Anzahl angeben bzw. die Ware abwiegen

Besonderheiten liegen bei der Erfassung von Artikeln ohne Barcode sowie bei der Erfassung von Getränken. Zu den Artikeln ohne Barcode gehören Obst, Gemüse und Backware. Diese können vom Kunden nicht gescannt werden. Stattdessen wählt der Kunde den entsprechenden Artikel auf dem Display aus und gibt anschließend die Anzahl ein oder wiegt das Produkt. Bei Getränken, die sowohl einzeln als auch im Paket angeboten werden, scannt der Kunde den Barcode der einzelnen Flasche und gibt anschließend ein, ob es sich um eine einzelne Flasche oder um ein Paket handelt (beispielsweise ein Träger bestehend aus sechs Flaschen).

### 1.2.2 Fehlerursachen bei Scanvorgängen

Bei Scanvorgängen kann es durch technische Probleme, durch Versehen oder durch Absicht zu Fehlern im Bezahlvorgang kommen. Bezogen auf die o.g. Anwendungsmöglichkeiten können diese Fehlerarten in der Praxis wie folgt differenziert werden:

#### 1. Technische Probleme

- Artikel wurde nicht gefunden
- Barcode nicht lesbar

#### 2. Versehen

- Artikel wurde vom Kunden übersehen
- Falsche Anzahl wurde eingegeben
- Falsches Produkt wurde ausgewählt

#### 3. Absicht

- Artikel wird bewusst nicht gescannt
- Artikel wird nachträglich storniert und behalten
- Zahlvorgang wird nicht abgeschlossen (Abbruch oder Ablehnung der Karte)
- Anzahl der Artikel wird falsch eingegeben
- Obst / Gemüse / Backware wird falsch ausgewählt (anderer günstigerer Artikel)
- Obst / Gemüse wird nicht vollständig abgewogen
- Statt des Artikels wird ein anderer günstigerer Artikel gescannt

Die Erkennung von Fehlern stellt eine große Herausforderung dar, da die Fehlerursachen vielfältig sind und in den Daten nicht unbedingt direkt erkennbar sein müssen.

### 1.3 Projektziel und Anforderungen

Ziel des Projekts ist es, die Anzahl inkorrekter Einkäufe im Einzelhandelsgeschäft der Auftraggeberin durch zielgerichtete Kontrollen verdächtiger Scanvorgänge zu reduzieren. Dabei sollen möglichst viele Falschscans aufgedeckt werden, denn jeder falsche Scanvorgang führt bei der Auftraggeberin durchschnittlich zu einem Verlust von 5 Euro. Ein aufgedeckter fehlerhafter Bezahlvorgang führt durchschnittlich zu einem Gewinn von 5 Euro. Allerdings ist es der Auftraggeberin wichtig, Kunden nicht zu Unrecht zu beschuldigen. Ein zu Unrecht beschuldigter Kunde würde im Durchschnitt zu einem Verlust von 25 Euro führen, da dieser das Geschäft anschließend wahrscheinlich meiden wird.

Ziel ist die Umsetzung eines Klassifikationsalgorithmus, der aufgrund noch festzulegender Attribute feststellt, ob eine Nachkontrolle eines Einkaufs vorzunehmen ist. Das System sollte für die Mitarbeiter möglichst nachvollziehbar sein. Den Mitarbeitern soll klar sein, aufgrund welcher Kriterien ein Einkauf als verdächtig eingestuft wurde. Das trainierte Modell soll auf neuen Daten eine möglichst geringe Fehlerquote aufweisen. Eine selbständige Anpassung des Modells ist nicht vorgesehen. Das Projekt wird bis zum 04.07.2024 abgeschlossen sein.

Des Weiteren soll der Auftraggeberin eine Komplettlösung aufgezeigt werden, wie die Daten aus dem jeweiligen Bezahlvorgang beim Algorithmus ankommen können, damit dieser eine Entscheidung treffen kann, wie und wo die Daten abgespeichert werden und wie man den Algorithmus auf den zusätzlichen Daten erneut trainieren kann.

### 1.4 Ressourcen und Handlungsalternativen

Angesichts der Vielzahl an Einkäufen sind Data-Science-Methoden wie Klassifikation, Regression oder Assoziationsregellernen ideal für diese Problemstellung geeignet. Zur Verfügung steht ein Datensatz, der Einkäufe an den SB-Kassen über zwei Jahre beinhaltet. Zudem steht ein Testdatensatz zur Verfügung, der zusätzliche Einkäufe über ein Jahr beinhaltet. Das Team besteht aus drei Data Scientists. Die Umsetzung erfolgt in Python.

Andere Lösungsansätze, die beispielsweise auf einer manuellen Mustererkennung basieren würden, werden aus Effizienzgründen nicht in Betracht gezogen.

# 2 Use-Case-Entwicklung

Im Rahmen des Projekts soll anhand eines Datensatzes über vergangene Einkäufe an SB-Kassen ein Systems zur Erkennung fehlerhafter Kassentransaktionen an SB-Kassen entwickelt werden. Das System soll an das bestehende Kassensystem angeschlossen werden und die Möglichkeit bieten, der Auftraggeberin ein parametrisiertes Dashboard anzeigen zu lassen.

Kunden sollen ihre Ware wie gewohnt selbst an der SB-Kasse scannen. Wird nun der Scanvorgang durch das System als verdächtig eingestuft, erfolgt ein Hinweis an einen Mitarbeiter, dass eine manuelle Nachkontrolle erfolgen soll. Wird keine Meldung ausgegeben, kann der Einkauf durch die Bezahlung wie üblich abgeschlossen werden.

Eine Kontrolle korrekter Scanvorgänge ist möglichst zu vermeiden, da dies zu unzufriedener Kundschaft und einem erhöhten Personalaufwand führen würde.

Ein Sub-Use-Case könnten sein, anhand der Daten ein Empfehlungssystem für Kunden zu entwickeln. Wenn bestimmte Artikel oft in Kombination gekauft werden, könnten fehlende Artikel empfohlen werden. Dieser Sub-Use-Case wird allerdings nicht im Rahmen dieses Projekts umgesetzt.

# 3 Eignungsprüfung

Da für die Problemlösung lediglich ein Datensatz zur Verfügung steht, ist Data Science eine geeignete Methode, um einen Klassifikationsalgorithmus für das Erkennen eines fehlerhaften Einkaufs (fehlerhafter Scanvorgang / korrekter Scanvorgang) zu erstellen. Aber auch die Regression und die Assoziationsregelanalyse sollten mit hoher Wahrscheinlichkeit zu einer Steigerung des Umsatzes durch Identifikation fehlerhafter Bezahlvorgänge führen. In Python stehen verschiedene Algorithmen zur Verfügung, die sich zum Bau eines Klassifikationsalgorithmus zur Erkennung fehlerhafter Scanvorgänge eignen. Eine Entwicklung eines eigenen Analyseverfahrens ist zum jetzigen Zeitpunkt nicht notwendig.

Als Datengrundlage dient ein Datensatz, der Einkäufe an SB-Kassen über einen Zeitraum von zwei Jahren beinhaltet. Dieser Datensatz enthält 104.464 Einkäufe mit den Attributen GUID, grand\_total, n\_items, total\_checkout\_time, line\_voids, most\_freq\_product, products, timestamp, payment\_medium, label, customer\_feedback und cash\_desk\_id. Dabei gibt das kategorische Attribut label an, ob es sich bei dem Einkauf um einen korrekten ("normal") oder um einen fehlerhaften Einkauf ("fraud") handelt, bei dem nicht alle Artikel erfasst wurden. Da es sich um einen gelabelten Datensatz handelt, der alle wichtigen Eigenschaften eines Einkaufs enthält, scheint dieser für das Vorgehen geeignet zu sein.

Der Aufwand für die Aufbereitung des Datensatzes erscheint überschaubar. Der Datensatz ist größtenteils vollständig, lediglich für das Attribut *customer\_feedback* fehlen Daten. Es existieren Attribute, die nicht benötigt werden und auch Attribute mit inkonsistenten Einträgen, die bereinigt werden müssen.

Vorhergehende bzw. ähnliche Projekte wurden von unserem Team nicht durchgeführt. Die Firma *GK-Software* hat bereits einen vergleichbaren Algorithmus auf den Markt gebracht, zu dem allerdings keine weiteren Informationen zur Verfügung stehen.

# 4 Sicherstellung der Umsetzbarkeit

Die vorhandene IT-Infrastruktur des Teams ist geeignet, um das geplante Vorgehen umzusetzen. Die Entwicklung des Modells soll in Python erfolgen, mit dem die drei Data Scientists vertraut sind. Kenntnisse im Bereich des maschinellen Lernen sind ebenfalls vorhanden, wodurch eine Umsetzbarkeit sichergestellt ist. Für die Entwicklung einer Datenbank, die Entwicklung einer Schnittstelle zu den SB-Kassen und die Auswahl einer entsprechenden Infrastruktur muss sich das Team zunächst in das Fachgebiet einarbeiten.

Risiken im Zusammenhang mit der Entwicklung eines Modells sind nicht zu erkennen. Der Datensatz enthält keine personenbezogenen Daten und Einkäufe sind nicht auf die Kunden zurückzuführen. Auch der Einsatz des geplanten Systems stellt nur ein geringes Risiko dar, sofern eine gute Genauigkeit auf dem Testdatensatz erreicht werden kann. Es besteht das Risiko von falschen Handlungsempfehlungen, wodurch es zu verärgerten Kunden und einem personellen Mehraufwand kommen kann.

Beim Abspeichern neuer Bezahlvorgänge an den SB-Kassen muss darauf geachtet werden, dass keine persönlichen Daten abgespeichert werden.

Da durch die Einführung des Systems ein Rückgang fehlerhafter Bezahlvorgänge zu erwarten ist und der Umsatz der Auftraggeberin voraussichtlich steigen wird, scheint der Aufwand und die Kosten des Projekts gerechtfertigt.

# 5 Projektausgestaltung

# 5.1 Geplante Arbeitsschritte

Um die genannten Anforderungen und Ziele des Projekts zu erreichen, sind folgende Arbeitsschritte notwendig:

### 1. Projektauftrag

- Beschreibung des Auftrags
- Darstellung des Projektziels
- Dokumentation anhand einer Projektskizze

### 2. Datenbereitstellung

- Erforschung und Aufbereitung der Daten
- Explorative Datenanalyse
- Erstellung eines finalen Datensatzes
- Dokumentation der Datenaufbereitung zur Nachvollziehbarkeit
- Bereitstellung der Ergebnisse der explorativen Datenanalyse

### 3. Analyse

- Trainieren verschiedener Algorithmen und Feature Selection auf dem Trainingsdatensatz
- Test und Evaluation der verschiedenen Ansätze
- Auswahl eines finalen Modells anhand noch festzulegender Kriterien
- Beschreibung und Dokumentation des finalen Algorithmus

### 4. Nutzbarmachung

- Beschreibung wie Algorithmus in IT-Infrastruktur eingebettet wird
- Beschreibung wie neue Daten gesammelt werden
- Beschreibung der Datenbank, in der neue Daten abgelegt werden
- Beschreibung wie und mit welcher Frequenz der Algorithmus auf neuen Daten trainiert werden kann

### 5. Nutzung

- Finalisierung aller projektbezogener Unterlagen und deren Übergabe
- Verwendung in der Domäne

# 5.2 Zeitplan

Das Projekt teilt sich in vier Phasen. Die Punkte *Nutzbarmachung* und *Nutzung* werden in einer gemeinsamen Phase zusammengefasst, da diese ineinander übergehen. Die voraussichtliche zeitliche Abfolge der oben genannten Schritte ist in Abbildung 1 dargestellt.




Abbildung 1: Projektskizze